AIoT · HW 2 · CRISP-DM + FEATURE SELECTION

洪水機率預測：多元線性迴歸完整分析

50,000 筆資料 × 20 個原始特徵 × 18 組模型比較

日期：2026-10-22 ｜程式：Python / scikit-learn ｜學號、姓名：由本人填寫

研究結果：依驗證集選出 All20 / LinearRegression，獨立測試集 RMSE = 8.547e-16、R^2 = 1.000000。這份資料的目標可由二十個輸入的線性總和精確還原，因此結果主要反映資料的生成規則。

完成範圍：分析、程式、互動網頁與本機文件已實作；GitHub / 網站繳交連結尚待確認，姓名、學號待填。依老師說明，整個第 4 項 AI 協助要求為選填，不列入待完成目標。

1. Business Understanding：商業理解

本研究建立可解釋的洪水機率分數預測流程。輸入環境、人口與基礎設施相關數值，預測連續目標 `FloodProbability`；這是迴歸任務，不將目標二元化。假想使用情境為教學性的風險篩選與模型比較，成功條件是優於僅預測訓練平均值的基準，並能重現特徵選擇、評估與新樣本預測。

原始資料來源未提供可驗證的地點、時間、實體量測單位或事件觀測機制，因此不能直接投入真實防災決策。若未來要實際部署，應加入獨立地區 / 期間驗證與來源查證，而非用本資料的 R^2 推論實務成效。

2. Data Understanding：資料理解

選用 Kaggle Flood Prediction Dataset 中的 `flood.csv` 同名公開鏡像。這份檔案有 50,000 列、21 欄；扣除目標後原始輸入為 20 個，符合 **13 < 特徵數 < 40**。這不是 1,117,957 列的競賽 `train.csv`，兩者不可混稱。

缺失值 0、完全重複列 0。目標範圍為 0.285–0.725。原始檔來自固定 GitHub commit 的鏡像，已記錄 Git blob 與本機 SHA-256；沒有宣稱曾以 Kaggle API 下載並核對位元組。

本機 `data/flood.csv` SHA-256：`4e32fac343580f686de0e65c7e088771d13c2995e71ee26a82fcee37bcf982d3`

特徵	中文對照	型態
MonsoonIntensity	季風強度	數值分數；無實體單位
TopographyDrainage	地形排水	數值分數；無實體單位
RiverManagement	河流管理	數值分數；無實體單位
Deforestation	森林砍伐	數值分數；無實體單位
Urbanization	都市化	數值分數；無實體單位
ClimateChange	氣候變遷	數值分數；無實體單位
DamsQuality	水壩品質	數值分數；無實體單位

特徵	中文對照	型態
Siltation	淤積	數值分數；無實體單位
AgriculturalPractices	農業活動	數值分數；無實體單位
Encroachments	侵占開發	數值分數；無實體單位
IneffectiveDisasterPreparedness	防災準備不足	數值分數；無實體單位
DrainageSystems	排水系統	數值分數；無實體單位
CoastalVulnerability	海岸脆弱度	數值分數；無實體單位
Landslides	山崩	數值分數；無實體單位
Watersheds	集水區	數值分數；無實體單位
DeterioratingInfrastructure	基礎設施劣化	數值分數；無實體單位
PopulationScore	人口分數	數值分數；無實體單位
WetlandLoss	濕地流失	數值分數；無實體單位
InadequatePlanning	規劃不足	數值分數；無實體單位
PoliticalFactors	政治因素	數值分數；無實體單位

表中中文為欄名對照，不自行賦予分數方向。尤其 RiverManagement、DrainageSystems 等名稱不代表實際量表為「品質越高越安全」；本檔的統計關係應以實測結果解讀。訓練集特徵相關矩陣、目標相關係數、完整描述統計分別保存在 `feature_correlations.csv`、`target_correlations.csv`、`data_description.csv`。

全資料目標平均 0.499660、樣本標準差 0.050034；Q1=0.465000、中位數=0.500000、Q3=0.535000。訓練集任兩輸入特徵的最大絕對 Pearson r 為 0.017394，輸入彼此相關很低。以下呈現訓練資料的目標相關係數前五名；最終仍依各 selector 的規則比較。

訓練集目標相關係數前 5 名	Pearson r
DeterioratingInfrastructure	0.232785
RiverManagement	0.230327
DamsQuality	0.229777
PoliticalFactors	0.228202
WetlandLoss	0.226727

> **資料生成規則**：完成模型比較後，描述性檢查發現 `FloodProbability = 0.005 × sum(20 features)`，全資料最大絕對差僅 1.110e-16。這是一項事後資料特性觀察，未用它重新挑選或修改模型。完美分數不代表真實世界中的完美預測。

3. Data Preparation：資料準備

固定 `random_state=42`，先隨機切成訓練 30,000 列、驗證 10,000 列、測試 10,000 列。對每個候選模型，`SimpleImputer(strategy="median") → StandardScaler → estimator` 的參數只從訓練資料估計。資料沒有缺失值，補值步驟仍保留以支援未來輸入；不補目標值。完整切分列索引保存在 `split_manifest.csv`。

五種 selector 皆不接觸外層驗證 / 測試目標，先在訓練資料建立 14 特徵子集；一般模型的 alpha 和最終勝出組合由外層驗證 RMSE 決定。測試分數僅為最終描述性比較，不根據測試表格重新選勝出模型。資料沒有類別特徵，主實驗不做 one-hot；額外 CSV 實驗室對類別欄採訓練資料建立編碼。

沒有以全資料刪除離群值或依目標進行特徵工程，避免人為改善測試成績。新輸入超過訓練範圍時屬外插；網頁顯示提示，仍保留模型原始輸出。

4. Modeling：建模與特徵選擇

依 scikit-learn 線性模型文件，一般線性迴歸最小化平方殘差；Ridge 加入 L2 係數懲罰；Lasso 使用 L1 懲罰，可能產生零係數。兩種正則化方法都先標準化。alpha 的選擇範圍：Ridge = 0.01、0.1、1、10、100；Lasso = 10^{-6}、10^{-5}、10^{-4}、10^{-3}、10^{-2}。

以完整 20 特徵作為基準，另比較五種 14 特徵子集。只有 20 個原始特徵，因此不勉強產生 25 或 30 特徵的版本。各 selector 的方法依據見 Feature selection，實作設定如下。

- **SelectKBest**：以 `f_regression` 單變量 F 分數選出前 14 欄。
- **RFE**：使用 Ridge(alpha=1) 逐步遞迴淘汰，保留 14 欄。
- **Sequential Feature Selection**：backward SFS，在固定抽樣的 5,000 筆訓練列上做 3 折 CV，以負 RMSE 評分；每折內各自補值與標準化。採子樣本是計算成本取捨，結果不代表在全部訓練列上最優。
- **Lasso 排名**：在標準化訓練資料上擬合 alpha=.001，再取絕對係數前 14 欄；這是 top-k 排名，不能聲稱 Lasso 恰好得到 14 個非零係數。
- **Permutation importance**：僅將外層訓練集內部切為 75% 擬合 / 25% 排名，以 Ridge(alpha=1)、5 次打亂造成的 RMSE 變化選前 14 欄。外層驗證和測試不參與排名。此重要性是模型與資料相關的預測指標，不是因果效果。

方法	入選特徵
All20	MonsoonIntensity、TopographyDrainage、RiverManagement、Deforestation、Urbanization、ClimateChange、DamsQuality、Siltation、AgriculturalPractices、Encroachments、IneffectiveDisasterPreparedness、DrainageSystems、CoastalVulnerability、Landslides、Watersheds、DeterioratingInfrastructure、PopulationScore、WetlandLoss、InadequatePlanning、PoliticalFactors
SelectKBest14	TopographyDrainage、RiverManagement、Urbanization、DamsQuality、Siltation、AgriculturalPractices、DrainageSystems、Landslides、Watersheds、DeterioratingInfrastructure、PopulationScore、WetlandLoss、InadequatePlanning、PoliticalFactors
RFE14	MonsoonIntensity、RiverManagement、ClimateChange、DamsQuality、Siltation、IneffectiveDisasterPreparedness、DrainageSystems、Landslides、Watersheds、DeterioratingInfrastructure、PopulationScore、WetlandLoss、InadequatePlanning、PoliticalFactors
SFS14	MonsoonIntensity、TopographyDrainage、RiverManagement、ClimateChange、Siltation、AgriculturalPractices、IneffectiveDisasterPreparedness、DrainageSystems、Landslides、DeterioratingInfrastructure、PopulationScore、WetlandLoss、InadequatePlanning、PoliticalFactors
Lasso14	TopographyDrainage、RiverManagement、Urbanization、DamsQuality、Siltation、AgriculturalPractices、DrainageSystems、CoastalVulnerability、Watersheds、DeterioratingInfrastructure、PopulationScore、WetlandLoss、InadequatePlanning、PoliticalFactors
Permutation14	TopographyDrainage、Deforestation、ClimateChange、DamsQuality、Siltation、AgriculturalPractices、Encroachments、IneffectiveDisasterPreparedness、DrainageSystems、Landslides、Watersheds、PopulationScore、InadequatePlanning、PoliticalFactors

6 種特徵組合 × 3 種模型 = 18 組。模型皆僅擬合外層訓練資料，沒有在選定參數後以 train+validation 重訓；匯出模型與報告評估的模型完全相同。

5. Evaluation：模型評估

MAE = mean(|y−ŷ|)；MSE = mean((y−ŷ)²)；RMSE = √MSE；$R^2 = 1-SSE/SST$；Adjusted $R^2 = 1-(1-R^2)(n-1)/(n-p-1)$；MAPE = mean(|(y−ŷ)/y|)×100%。MAPE 排除 y=0 的列並記錄數量，本測試集無須排除。Adjusted R^2 此處用測試樣本 n=10,000 與欄位數 p；Ridge/Lasso 的有效自由度不等於 p，因此僅作描述比較。

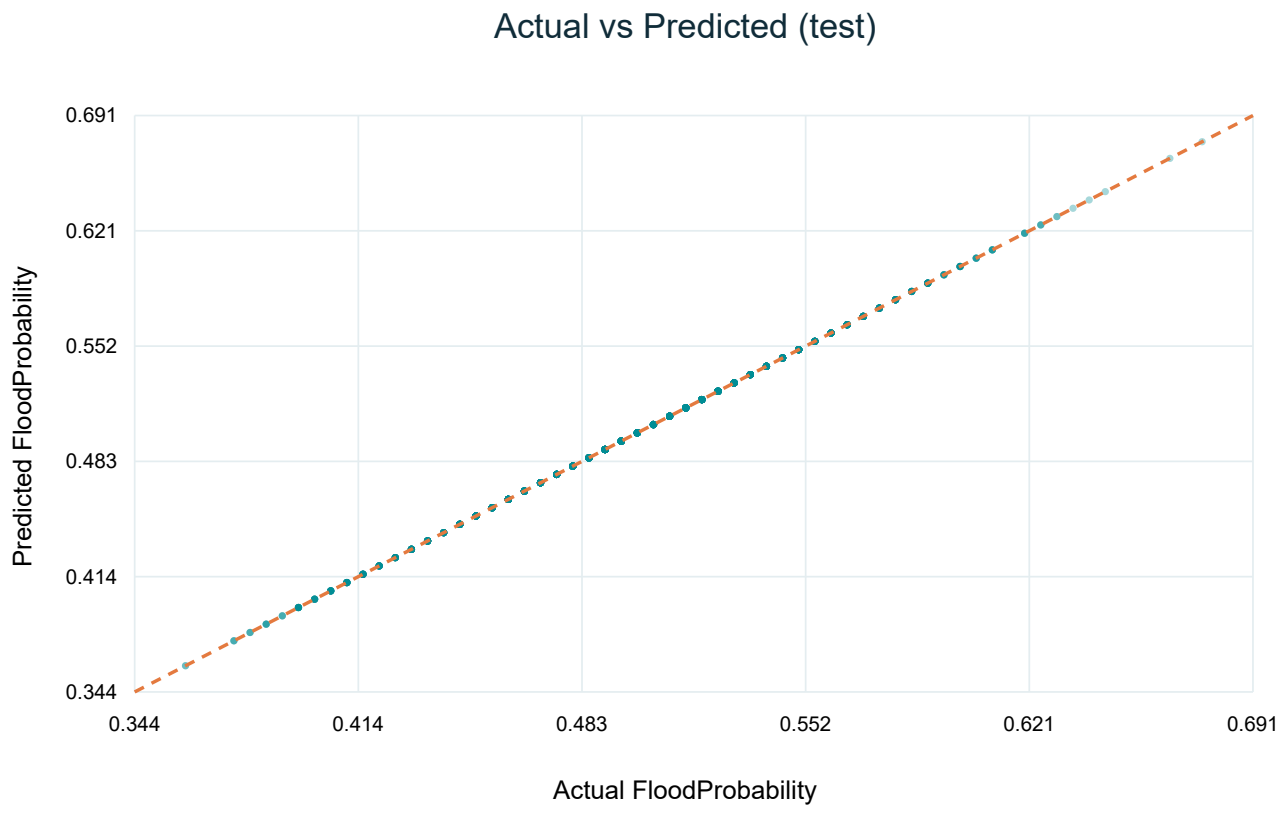
特徵 / 模型	p	alpha	驗證 RMSE	測試 MAE	MSE	RMSE	R^2	Adj. R^2	MAPE %
All20 / LinearRegression	20	—	8.545e-16	6.806e-16	7.305e-31	8.547e-16	1.000000	1.000000	1.374e-13
All20 / Ridge	20	0.01	1.681e-08	1.331e-08	2.785e-16	1.669e-08	1.000000	1.000000	2.709e-06
All20 / Lasso	20	1e-06	4.515e-06	3.577e-06	2.010e-11	4.483e-06	1.000000	1.000000	0.000728
SelectKBest14 / LinearRegression	14	—	0.027467	0.021867	0.000753	0.027445	0.698778	0.698355	4.416932

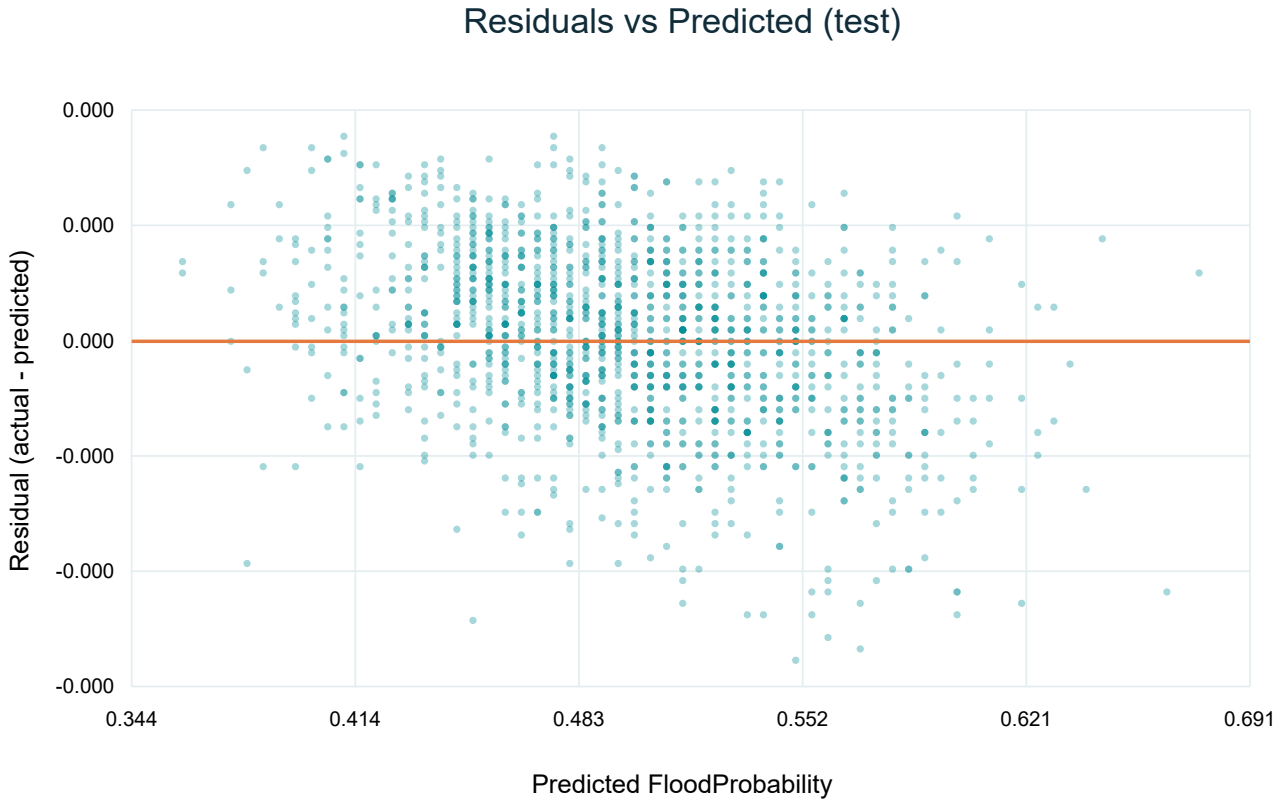
特徵 / 模型	p	alpha	驗證 RMSE	測試 MAE	MSE	RMSE	R^2	Adj. R^2	MAPE %
SelectKBest14 / Ridge	14	0.01	0.027467	0.021867	0.000753	0.027445	0.698778	0.698355	4.416933
SelectKBest14 / Lasso	14	1e-06	0.027467	0.021867	0.000753	0.027445	0.698776	0.698354	4.416962
RFE14 / LinearRegression	14	—	0.027698	0.021605	0.000735	0.027117	0.705929	0.705517	4.366042
RFE14 / Ridge	14	10	0.027698	0.021605	0.000735	0.027117	0.705931	0.705519	4.366009
RFE14 / Lasso	14	1e-05	0.027698	0.021604	0.000735	0.027117	0.705935	0.705523	4.365971
SFS14 / LinearRegression	14	—	0.027512	0.021815	0.000749	0.027369	0.700442	0.700022	4.401344
SFS14 / Ridge	14	0.01	0.027512	0.021815	0.000749	0.027369	0.700442	0.700022	4.401344
SFS14 / Lasso	14	1e-06	0.027512	0.021815	0.000749	0.027369	0.700442	0.700022	4.401345
Lasso14 / LinearRegression	14	—	0.027439	0.021871	0.000754	0.027462	0.698401	0.697978	4.420657
Lasso14 / Ridge	14	0.01	0.027439	0.021871	0.000754	0.027462	0.698401	0.697978	4.420657
Lasso14 / Lasso	14	1e-06	0.027439	0.021871	0.000754	0.027462	0.698400	0.697977	4.420677
Permutation14 / LinearRegression	14	—	0.027600	0.021935	0.000756	0.027495	0.697666	0.697242	4.425279
Permutation14 / Ridge	14	10	0.027600	0.021934	0.000756	0.027495	0.697671	0.697247	4.425234
Permutation14 / Lasso	14	1e-06	0.027600	0.021934	0.000756	0.027495	0.697667	0.697243	4.425267

僅預測訓練平均值的基準測試 RMSE = 0.050006、MAE = 0.039882、R^2 = -4.228e-05。完整特徵一般線性模型幾乎精確還原目標；14 特徵線性模型 R^2 約 0.70，說明本資料的二十個因子都攜帶資訊，刪除欄位會損失預測能力。正則化在此資料上沒有帶來實質改善，過強懲罰反而產生偏差。

實際值與預測值、殘差圖

最佳模型完整測試指標使用 10,000 筆；圖為固定最多 1,500 筆視覺抽樣。殘差 = 實際 − 預測。全特徵殘差只有浮點誤差，縱軸放大不代表實質預測誤差。

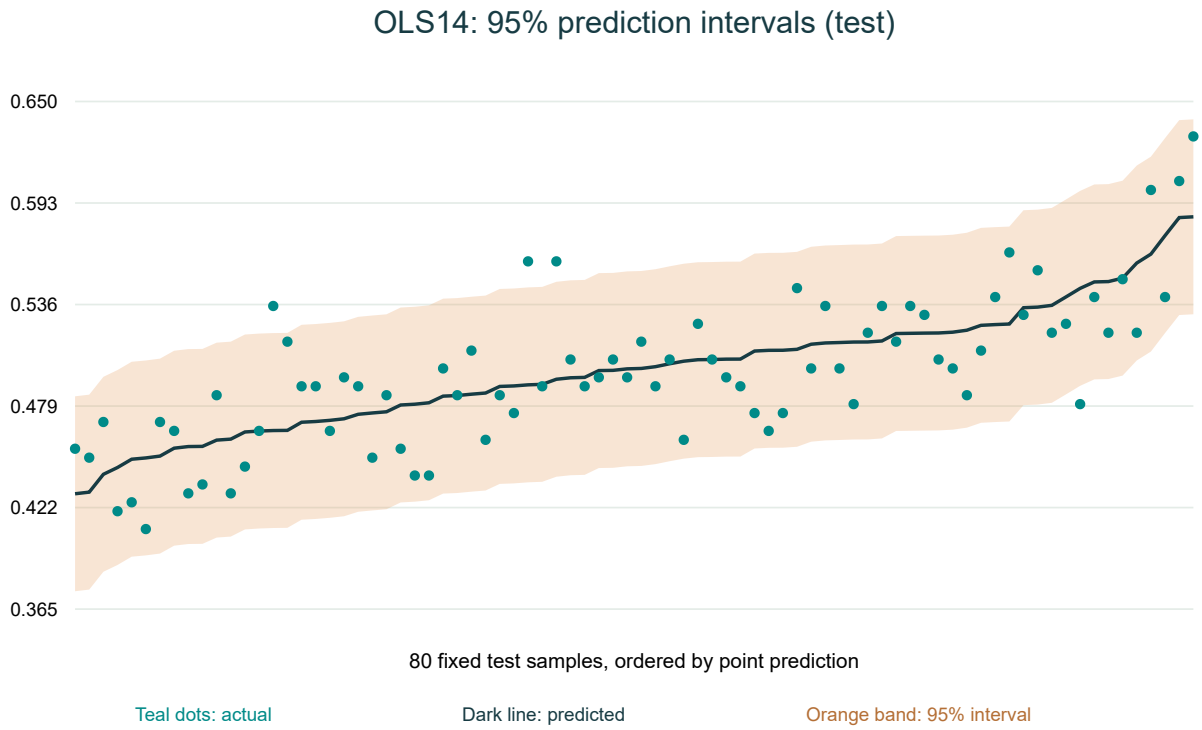




95% 預測區間：新觀測值的不確定性

為滿足題目「預測圖加上信賴區間或預測區間」要求，另外固定使用 **SelectKBest14 / LinearRegression** 產生 split conformal 預測區間，方法依據 Angelopoulos 與 Bates 的 conformal prediction 教程。其特徵選擇與模型只由訓練資料決定，此輔助模型不使用驗證目標挑選模型或 alpha；將 10,000 筆驗證列另作它的校準資料。以校準絕對殘差排序，取第 ceil((n_cal+1)×0.95) = 9501 小的值 q = 0.054611，對每筆測試預測建立 [ŷ−q, ŷ+q]。測試資料沒有用來調整區間寬度。

10,000 筆獨立測試的實際涵蓋率為 **94.97%**，平均區間寬度 0.109222。圖中顯示固定抽樣 80 筆測試觀測，依點預測排序，橘色帶為預測區間、綠點為實際值。這是新觀測值的預測區間，不是條件平均的信賴區間；名目邊際涵蓋性依賴校準與未來觀測的交換性，不保證每個輸入條件或真實地區的涵蓋率。完整 20 特徵模型區間會縮至浮點誤差，因此不把該退化區間當成真實預測確定性。



五項迴歸假設檢查

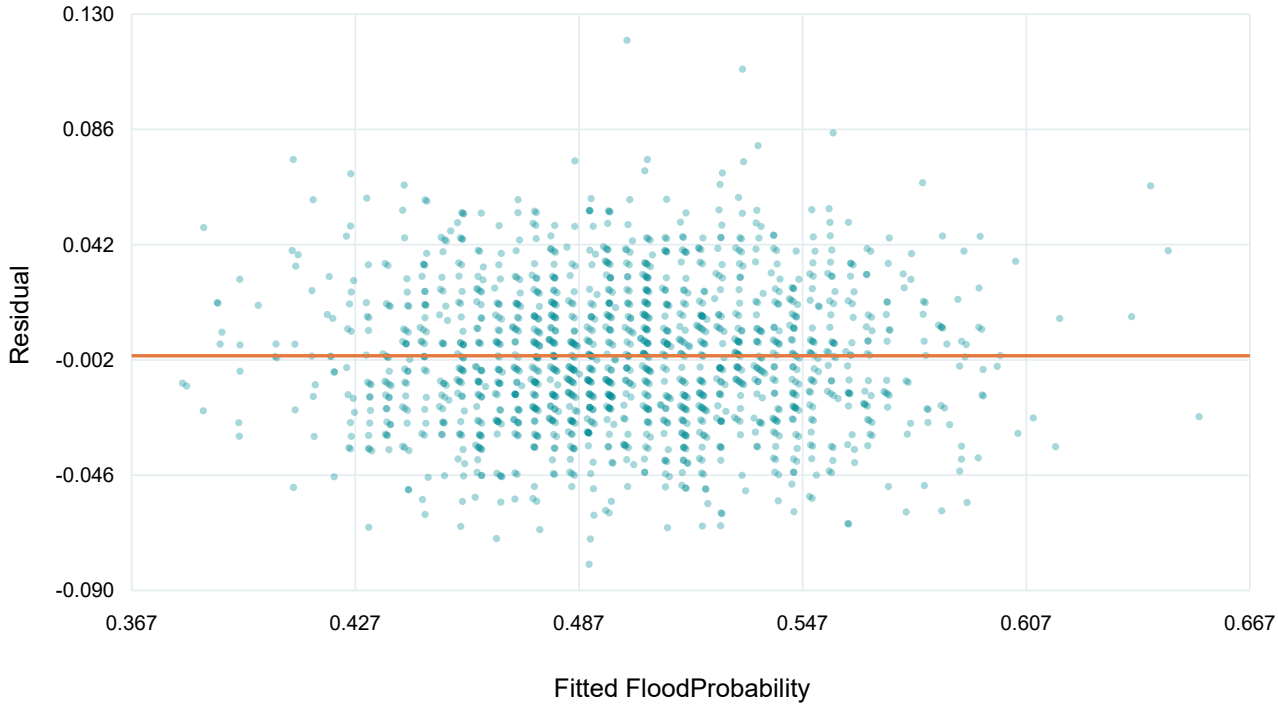
依 迴歸診斷文件的定義檢查線性、獨立性、等變異、殘差常態與共線性。主實驗使用 NumPy/SciPy 實作輔助迴歸和統計分布，沒有安裝 statsmodels；各檢定公式在程式中註明。完整 20 特徵 OLS 的前四項檢定因殘差接近零而退化，不解讀浮點誤差產生的 p-value；完整模型最大 VIF = 1.001002。

以下改用 **SelectKBest14 / LinearRegression 的訓練殘差**診斷（n=30,000），並保留一般條件與解讀限制：

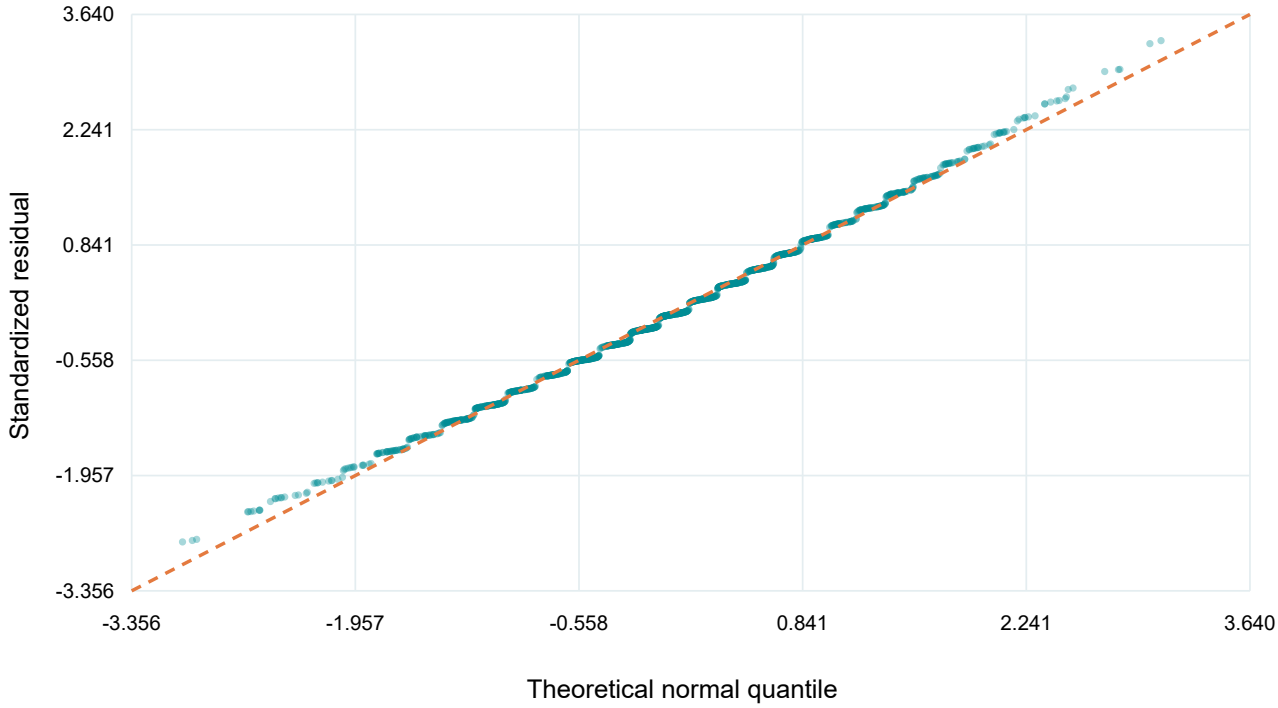
假設	檢查方式	統計量	p-value	判讀
線性關係	Ramsey RESET (powers 2, 3)	0.020490	0.979718	未發現足夠違反證據
殘差獨立性	Durbin–Watson (descriptive)	2.003520	—	缺少時間 / 群組資訊，無法確認
等變異性	Koenker–Breusch–Pagan LM	12.675083	0.552252	未發現足夠違反證據
殘差常態性	Jarque–Bera	195.204636	4.091e-43	有違反假設的證據
無嚴重多重共線性	Maximum VIF	1.000812	—	未見嚴重共線性

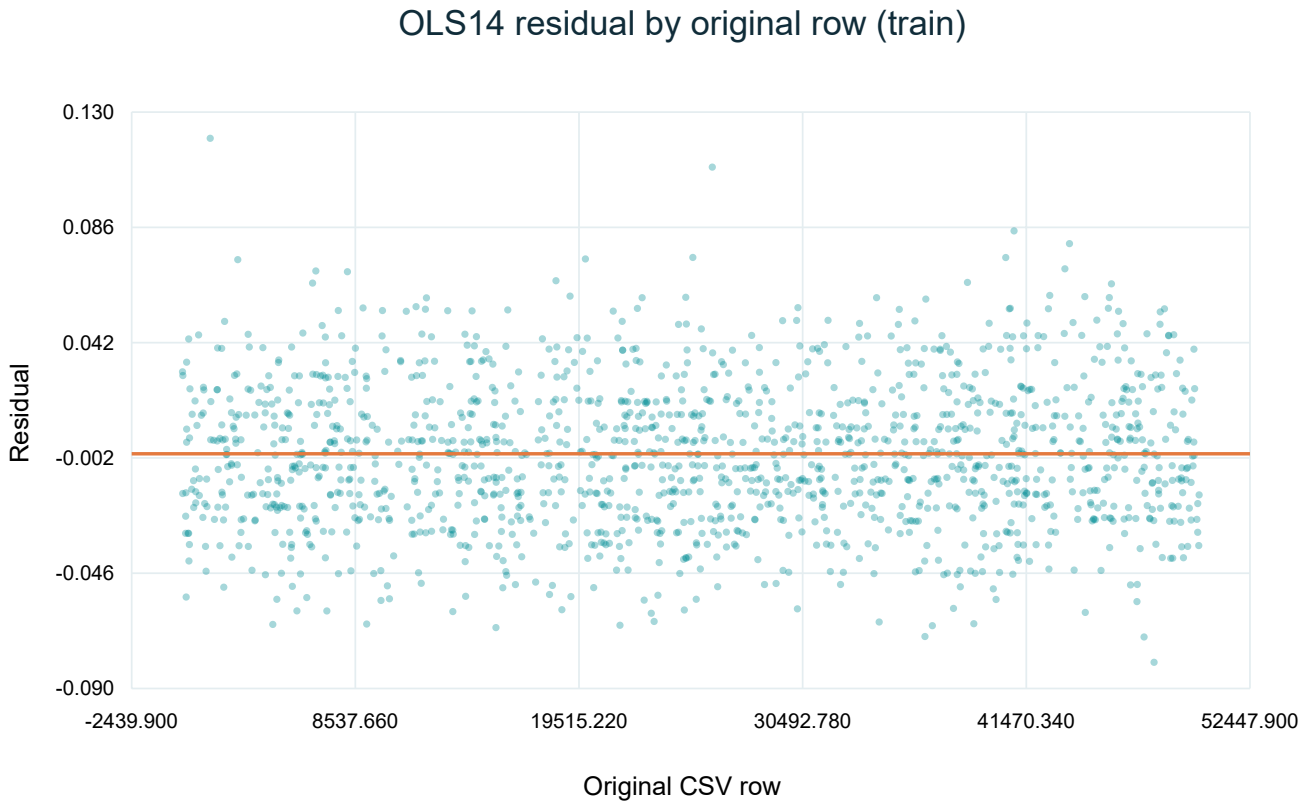
- 線性：RESET 比較原模型與加入擬合值二次 / 三次項的擴充模型，F 檢定未發現函數形式不足的充分證據。
- 獨立性：依原始 CSV 列序排列訓練殘差，DW 接近 2；因沒有實際時間或群組資訊，仍**無法確認觀測獨立性**。
- 等變異：以殘差平方對設計矩陣做輔助迴歸，Koenker–BP 的 LM=n×R²，卡方自由度為設計矩陣秩減 1；未拒絕等變異。
- 常態性：Jarque–Bera 拒絕殘差常態，需配合 Q–Q 圖判讀，且大樣本對微小偏離敏感。這不會使樣本外預測指標失效；若要傳統係數推論或區間，須另評估穩健標準誤 / bootstrap。
- 共線性：逐一以其他變項預測該特徵，VIF=1/(1−R²)，最大值接近 1，未見嚴重共線性。VIF>5 僅為關注門檻。

OLS14 residuals vs fitted (train)



OLS14 residual Q-Q (train)





6. Deployment：預測與展示

模型包含訓練中位數、平均值、標準差、係數與截距，以 JSON 匯出；網頁直接使用同一組參數，無須安裝套件即可執行單筆預測。Python 批次預測指令：

```
python scripts/predict.py data/new_samples.csv --output results/predictions.csv
```

本模型的原始單位方程式約為 ŷ = 0 + 0.005×MonsoonIntensity + … + 0.005×PoliticalFactors。單個特徵增加 1，其餘固定時，模型輸出約增加 0.005；這是本資料的模型關係，不是現實中的因果結論。三筆新樣本輸入與預測保存在 `data/new_samples.csv` 和 `results/new_predictions.csv`。

互動頁提供模型選擇、六指標、散佈圖、殘差圖、特徵名單及新樣本輸入。互動分析採 **單一分析區與資料集下拉選單**，可選 Flood、50 Startups 或自選資料集；選自選資料集時顯示 **CSV 檔案 / 網址匯入**。網址需為公開 HTTP(S) CSV，且來源伺服器允許跨來源存取；讀取失敗可改用下載後的檔案。類別欄在訓練集建立 one-hot，省略首類避免虛擬變項共線性；未知或缺失類別回到基準編碼。瀏覽器端最多 50,000 列、39 個原始輸入與 100 個編碼欄位。

50 Startups 原始輸入只有 4 欄，僅作為題目允許的任意 CSV 匯入範例，不拿它充當符合 14–39 特徵條件的主資料。瀏覽器以固定 seed=42 重新分割 60/20/20；alpha 為使用者設定，沒有自動調參。瀏覽器實驗與正式 Python 結果獨立。

7. 選填項目說明

依老師說明，整個「4. AI 協助要求」為選填，包含 GPT 輔助內容標示、AI 使用與對話紀錄、對話 PDF，以及 NotebookLM 研究與至少 100 字摘要。以上均不列入必做或待完成目標。

8. 重現與成果對照

```
python -m venv .venv
# Windows PowerShell
.\.venv\Scripts\python.exe -m pip install -r requirements.txt
.\.venv\Scripts\python.exe scripts/analyze.py
.\.venv\Scripts\python.exe scripts/build_report.py
.\.venv\Scripts\python.exe -m unittest discover -s tests
node tests/test_browser_core.cjs
```

此專案已附原始 CSV，可離線重跑分析；第一次建立環境仍需安裝套件。已建立的本機 `.venv` 可直接使用，不需重新安裝。版本：{"python": "3.11.9", "numpy": "2.4.6", "pandas": "3.0.5", "scipy": "1.17.1", "sklearn": "1.9.0"}。

題目要求	成果
Kaggle 14–39 個原始特徵	20 特徵 flood.csv；來源、固定鏡像與 SHA-256 已記錄
CRISP-DM 六階段	本報告第 1–6 節與 Notebook
五種特徵選擇、三種模型	18 組比較、selected_features.csv、validation_search.csv
六項指標及五大假設	model_comparison.csv；全模型退化註記與 14 特徵補充診斷
結果圖、95% 預測區間與新樣本	SVG 圖表、split conformal 區間、互動圖、predict.py 與 new_predictions.csv
網頁、資料集切換、任意 CSV	web/dist/index.html；單一分析區載入、訓練、下載
第 4 項 AI 協助要求（選填）	含 GPT 使用紀錄、對話 PDF 與 NotebookLM 研究摘要；均不列入待完成目標
GitHub / web 繳交	本機網頁已完成；repository 與已發布網站的繳交連結尚待確認
報告基本資料	姓名、學號待填，並同步更新 HTML / PDF

9. 參考來源

1. Kaggle Flood Prediction Dataset
2. 實際讀取檔案的公開鏡像（固定 commit）
3. scikit-learn：Feature selection
4. scikit-learn：Common pitfalls / data leakage
5. scikit-learn：Linear models
6. scikit-learn：Permutation importance
7. statsmodels：Regression diagnostics
8. Angelopoulos & Bates：A Gentle Introduction to Conformal Prediction
9. 加分示範：50 Startups CSV

來源查閱：2026-10-22。分析與網頁均可離線使用；外部來源連結需網路。資料授權 / 來源以原提供者資訊為準，本專案未重新宣稱原始資料的授權。